

UNIVERSIDAD AUTÓNOMA DEL CARMEN

FACULTAD DE CIENCIAS DE LA INFORMACIÓN

CARRERA: LICENCIATURA EN ING EN SISTEMAS COMPUTACIONALES

ALUMNO(A): MARIO GARCIA CASTILLO

PROFESOR: JESÚS ALEJANDRO FLORES HERNÁNDEZ

MATERIA: PROGRAMACIÓN AVANZADA

FECHA: 31 DE AGOSTO DE 2026

Análisis y Aplicación de ID3 al Dataset Iris

Debido a que la versión clásica del algoritmo ID3 está concebida para procesar únicamente variables categóricas o discretas, fue imperativo aplicar un preprocesamiento al conjunto de datos *Iris*. Dado que este incluye atributos con valores continuos, se empleó la mediana estadística de cada característica como punto de corte, logrando así dividir cada variable en dos rangos categóricos: **Bajo** (valores menores o iguales a la mediana) y **Alto** (valores superiores a la mediana).

- **sepal (Longitud del sépal):** Mediana = 5.80 cm → Bajo: ≤ 5.80 (80 registros) | Alto: > 5.80 (70 registros)
- **sepalw (Anchura del sépal):** Mediana = 3.00 cm → Bajo: ≤ 3.00 (83 registros) | Alto: > 3.00 (67 registros)
- **petal (Longitud del pétalo):** Mediana = 4.35 cm → Bajo: ≤ 4.35 (75 registros) | Alto: > 4.35 (75 registros)
- **petalw (Anchura del pétalo):** Mediana = 1.30 cm → Bajo: ≤ 1.30 (78 registros) | Alto: > 1.30 (72 registros)

	A	B	C	D	E	F
1	sepal (Largo)	sepalw (Ancho)	petal (Largo)	petalw (Ancho)	clase	
2	Bajo	Alto	Bajo	Bajo	Iris-setosa	
3	Bajo	Bajo	Bajo	Bajo	Iris-setosa	
4	Bajo	Alto	Bajo	Bajo	Iris-setosa	
5	Bajo	Alto	Bajo	Bajo	Iris-setosa	
6	Bajo	Alto	Bajo	Bajo	Iris-setosa	
7	Bajo	Alto	Bajo	Bajo	Iris-setosa	
8	Bajo	Alto	Bajo	Bajo	Iris-setosa	
9	Bajo	Alto	Bajo	Bajo	Iris-setosa	
10	Bajo	Bajo	Bajo	Bajo	Iris-setosa	
11	Bajo	Alto	Bajo	Bajo	Iris-setosa	
12	Bajo	Alto	Bajo	Bajo	Iris-setosa	
13	Bajo	Alto	Bajo	Bajo	Iris-setosa	
14	Bajo	Bajo	Bajo	Bajo	Iris-setosa	
15	Bajo	Bajo	Bajo	Bajo	Iris-setosa	
16	Bajo	Alto	Bajo	Bajo	Iris-setosa	
17	Bajo	Alto	Bajo	Bajo	Iris-setosa	
18	Bajo	Alto	Bajo	Bajo	Iris-setosa	
19	Bajo	Alto	Bajo	Bajo	Iris-setosa	
20	Bajo	Alto	Bajo	Bajo	Iris-setosa	
21	Bajo	Alto	Bajo	Bajo	Iris-setosa	
22	Bajo	Alto	Bajo	Bajo	Iris-setosa	
23	Bajo	Alto	Bajo	Bajo	Iris-setosa	
24	Bajo	Alto	Bajo	Bajo	Iris-setosa	
25	Bajo	Alto	Bajo	Bajo	Iris-setosa	
26	Bajo	Alto	Bajo	Bajo	Iris-setosa	
27	Bajo	Bajo	Bajo	Bajo	Iris-setosa	

< > iris-dizcretizado +

1. Cálculo de Entropía del Conjunto Global (S)

El conjunto principal S agrupa N = 150 instancias, las cuales se encuentran distribuidas equitativamente entre tres clases: 50 Iris-setosa, 50 Iris-versicolor y 50 Iris-virginica.

$$\text{Entropía}(S) = - \sum p_i \log_2(p_i)$$

Sustituyendo las probabilidades correspondientes para cada clase ($p_i = 50/150 = 1/3$):

$$\text{Entropía}(S) = - [(1/3)\log_2(1/3) + (1/3)\log_2(1/3) + (1/3)\log_2(1/3)] \approx 1.5850 \text{ bits}$$

2. Elección del Nodo Raíz mediante Ganancia de Información

Para determinar qué atributo ocupará el nodo raíz, se obtuvo la ganancia de información para las cuatro variables discretizadas.

A) petalw (Anchura del pétalo)

- petalw = 'Bajo' (78 instancias: 50 setosa, 28 versicolor, 0 virginica): Entropía = - ((50/78) $\log_2$ (50/78) + (28/78) $\log_2$ (28/78)) = 0.9418 bits
- petalw = 'Alto' (72 instancias: 0 setosa, 22 versicolor, 50 virginica): Entropía = - ((22/72) $\log_2$ (22/72) + (50/72) $\log_2$ (50/72)) = 0.8880 bits
- Entropía promedio ponderada: (78/150)(0.9418) + (72/150)(0.8880) = 0.9160 bits
- **Ganancia (S, petalw) = 1.5850 - 0.9160 = 0.6690 bits**

B) petall (Longitud del pétalo)

- petall = 'Bajo' (75 instancias: 50 setosa, 25 versicolor, 0 virginica) → Entropía = 0.9183 bits
- petall = 'Alto' (75 instancias: 0 setosa, 25 versicolor, 50 virginica) → Entropía = 0.9183 bits
- Entropía promedio ponderada: (75/150)(0.9183) + (75/150)(0.9183) = 0.9183 bits
- **Ganancia (S, petall) = 1.5850 - 0.9183 = 0.6667 bits**

C) sepall (Longitud del sépalos)

- sepall = 'Bajo' (80 instancias: 50 setosa, 24 versicolor, 6 virginica) → Entropía = 1.2252 bits
- sepall = 'Alto' (70 instancias: 0 setosa, 26 versicolor, 44 virginica) → Entropía = 0.9518 bits
- Entropía promedio ponderada: (80/150)(1.2252) + (70/150)(0.9518) = 1.0976 bits
- **Ganancia (S, sepall) = 1.5850 - 1.0976 = 0.4874 bits**

D) sepalw (Anchura del sépalos)

- sepalw = 'Bajo' (83 instancias: 8 setosa, 42 versicolor, 33 virginica) → Entropía = 1.3516 bits
- sepalw = 'Alto' (67 instancias: 42 setosa, 8 versicolor, 17 virginica) → Entropía = 1.2905 bits
- Entropía promedio ponderada: (83/150)(1.3516) + (67/150)(1.2905) = 1.3244 bits
- **Ganancia (S, sepalw) = 1.5850 - 1.3244 = 0.2606 bits**

Resolución de la etapa: Dado que el atributo **petalw** proporciona la máxima ganancia de información con un valor de 0.6690, es designado como el nodo raíz del árbol.

3. Ramificación y Construcción Recursiva

Primera Rama: petalw = 'Bajo' (78 instancias totales: 50 setosa, 28 versicolor, 0 virginica)

Al calcular nuevamente la ganancia para este grupo en base a los demás atributos, resulta:

- Ganancia (sepalw) = 0.5891 (Mayor ganancia obtenida)
- Ganancia (sepal) = 0.1444
- Ganancia (petall) = 0.1005

Empleando **sepalw** para subdividir:

- En caso de sepalw = 'Alto': Hay 42 registros, que recaen totalmente en Iris-setosa. Esto establece una entropía de 0 y culmina en un nodo hoja puro: **Iris-setosa**.
- En caso de sepalw = 'Bajo': Quedan 36 registros (28 versicolor, 8 setosa). Al analizar el siguiente mejor evaluado (sepal, con 0.0797 de ganancia):
 - sepal = 'Alto': Agrupa 7 casos, todos pertenecientes a Iris-versicolor. Nodo hoja puro: **Iris-versicolor**.
 - sepal = 'Bajo': Concentra 29 casos (21 versicolor, 8 setosa). Al carecer de más divisiones que generen pureza absoluta, se adopta la clase mayoritaria: **Iris-versicolor**.


Segunda Rama: petalw = 'Alto' (72 instancias totales: 0 setosa, 22 versicolor, 50 virginica)

Las nuevas ganancias sobre este subconjunto indican lo siguiente:

- Ganancia (petall) = 0.0488 (Mayor ganancia obtenida)
- Ganancia (sepal) = 0.0004
- Ganancia (sepalw) = 0.0004

Empleando **petall** para subdividir:

- En caso de petall = 'Bajo': Solo existen 2 registros y ambos caen en la clase Iris-versicolor. Su entropía nula marca un nodo hoja puro: **Iris-versicolor**.
- En caso de petall = 'Alto': Restan 70 registros (50 virginica y 20 versicolor). Puesto que no se generan subdivisiones más puras con los atributos sobrantes, se dictamina el final de la rama por mayoría, clasificando como: **Iris-virginica**.



4. Extracción de las Reglas de Decisión

1. **SI** petalw es 'Bajo' **Y** sepalw es 'Alto', **ENTONCES** la clase predicha es Iris-setosa (*Acierto de 42/42 casos, pureza 100%*).
2. **SI** petalw es 'Bajo' **Y** sepalw es 'Bajo' **Y** sepall es 'Alto', **ENTONCES** la clase predicha es Iris-versicolor (*Acierto de 7/7 casos, pureza 100%*).
3. **SI** petalw es 'Bajo' **Y** sepalw es 'Bajo' **Y** sepall es 'Bajo', **ENTONCES** la clase predicha es Iris-versicolor (*Determinación mayoritaria: 21 de 29 casos*).
4. **SI** petalw es 'Alto' **Y** petall es 'Bajo', **ENTONCES** la clase predicha es Iris-versicolor (*Acierto de 2/2 casos, pureza 100%*).
5. **SI** petalw es 'Alto' **Y** petall es 'Alto', **ENTONCES** la clase predicha es Iris-virginica (*Determinación mayoritaria: 50 de 70 casos*).

Tree View

